

Rīgas Valsts klasiskā ģimnāzija

**MĀKSLĪGO NEIRONU TĪKLU PIELIETOŠANAS IESPĒJU ANALĪZE  
SEJAS ATPAZĪŠANAI NEPILNAS VAI IEROBEŽOTAS VIZUĀLĀS  
INFORMĀCIJAS APSTĀKĻOS**

Zinātniskās pētniecības darbs datorzinātnes nozarē

**Darba autori:**

11. klases skolēni  
Artemijs Čudinovs  
Mihails Danilovs  
Roberts K. Zveja

**Darba vadītājs:**

Dr.sc.ing. Sergejs Paršutins

Rīga, 2021

## ANOTĀCIJA

Attīstoties datoru tehnoloģijām kļuva iespējams efektīvi pielietot pagājušā gadsimta vidū piedāvāto tehnoloģiju – mākslīgos neironu tīklus. Mākslīgie neironu tīkli parādīja augstu efektivitāti dažādu vairāku uzdevumu risināšanai, t.sk. sejas atpazīšanas uzdevumā.

Sejas noteikšana un atpazīšana ir viena no galvenajām autentifikācijas sistēmām, kuras pamatā ir biometriskie dati, kurus var izmantot autentifikācijas procesā, kā arī uzraudzībā. Mūsdienās populārākā no sejas atpazīšanas tehnoloģijām ir dziļie mākslīgie neironu tīkli. To apmācīšanai ir nepieciešami plašie datu avoti un bieži vien tiek izmantoti seju attēli, kur seja ir labi redzama, kas ir šādu sistēmu vāja vieta. Tomēr reālajā dzīvē analizējami dati nesatur pilnu (ideālu) informāciju par identificējamo personu.

**Darba mērķis** ir izpētīt neironu tīklu efektivitāti sejas atpazīšanai ierobežotas informācijas apstākļos. **Pētījuma jautājums:** Cik efektīvs ir mākslīgais neironu tīkls sejas atpazīšanai ierobežotās informācijas apstākļos? Mērķa sasniegšanai tika veikta literatūras un informācijas avotu analīze par mākslīgiem neironu tīkliem, to struktūru un apmācības algoritmiem. Tika izpētīti mākslīgo neironu pielietošanas veidi sejas atpazīšanai. Tika sagatavotas datu kopas no 134 attēliem, kur 78 satur atklātas sejas un 56 satur daļēji nosegtas sejas. Eksperimentu rezultātā mākslīgais neironu tīkls veiksmīgi atpazīna atklātas sejas un slikti atpazīna daļēji nosegtas sejas. Tika secināts, ka *YOLOv3* tīkls tika pamācīts uz datu kopas, kura saturēja tikai atklātas sejas, tāpēc tas parādīja sliktus rezultātus, atpazīnot daļēji nosegtas sejas. Kopumā visi uzdevumi ir izpildīti un definētais mērķis ir sasniegts.

**Atslēgvārdi:** datorredze, sejas atpazīšana, mākslīgie neironu tīkli, mašīnmācīšanās.

## ANNOTATION

As the computer technologies develop, it became possible to effectively use the technology, that was offered in the middle of the last century - artificial neural networks. Artificial neural networks have shown high efficiency for solving various tasks, incl. the face recognition task.

Face detection and recognition is one of the main authentication systems based on biometric data that can be used in the authentication process as well as in monitoring. Today, the most popular of the face recognition technologies are deep artificial neural networks. Their training requires extensive data sources and often uses face images where the face is clearly visible, which is a weak point of such systems. However, data analyzed in real life does not contain complete (ideal) information about the identifiable person.

**The goal of this work** is to study the efficiency of neural networks for face recognition in conditions of limited information. **Research question:** How effective is an artificial neural network for face recognition in conditions of limited information? To achieve the goal, an analysis of literature and information sources on artificial neural networks, their structure and training algorithms was performed. The applications of artificial neurons for face recognition were studied. Data sets were prepared from 134 images, where 78 contain open faces and 56 contain partially covered faces. As a result of the experiments, the artificial neural network successfully recognized open faces and poorly recognized partially covered faces. It was concluded that the *YOLOv3* network was trained on a dataset that contained only open faces, so it showed poor results in recognizing partially covered faces. In general, all tasks have been completed and the defined goal has been achieved.

**Keywords:** computer vision, face recognition, artificial neural networks, machine learning.

## SATURS

Ievads .....	4
1. Teorētiskā daļa.....	5
1.1. Mākslīgie neironu tīkli .....	5
1.2. Mākslīgie neironu tīkli sejas atpazīšanas uzdevumā .....	7
2. Praktiskā daļa.....	9
Secinājumi.....	10
Literatūras un informāciju avotu saraksts .....	11
Pielikumi .....	12

## IEVADS

Sejas noteikšana un atpazīšana ir viena no galvenajām autentifikācijas sistēmām, kuras pamatā ir biometriskie dati, kurus var izmantot autentifikācijas procesā, kā arī uzraudzībā. Ar katru dienu strauji pieaugošo krāpšanos sejas atpazīšana kļūst par izšķirošu. Efektīvas sejas atpazīšanas sistēmas dažādi pielietojumi ir kriminālistika, noziedznieku identificēšana, uzraudzība, krāpšanas izslēgšana u.c. Sejas atpazīšana vienmēr ir bijusi ļoti sarežģīts un izaicinošs uzdevums. Tās faktiskais pārbaudījums ir automatizētas iezīmēšana ietvars, kas paralēli cilvēka spējai uztvert sejas. Lai kā arī būtu, cilvēka spēja ir ierobežota, kad tā pārvalda daudz neskaidru izskatu. Līdz ar to ieprogrammēts automatizēts elektroniskais ietvars ar salīdzinoši nepieciešama lielāka atpazīšanas precizitāti un ātra apstrāde [1].

Mūsdienās populārākā no sejas atpazīšanas tehnoloģijām ir dziļie mākslīgie neironu tīkli. To apmācīšanai ir nepieciešami plašie datu avoti un bieži vien tiek izmantoti seju attēli, kur seja ir labi redzama, kas ir šādu sistēmu vāja vieta. Tomēr reālajā dzīvē analizējami dati nesatur pilnu (ideālu) informāciju par identificējamo personu. Attēlam var būt sliktā kvalitāte vai arī ir redzama tikai daļa no personas sejas – galva var būt pagriezta vai arī persona lieto masku, kas COVID-19 pandēmijas laikā ir ierasta lieta. Šādos gadījumos ir grūti pateikt kā uzvedīsies sejas kontroles sistēma, ja tā tika apmācīta, jeb orientēta uz pilnīgi redzamas sejas atpazīšanu un nebija testēta daļēji pieejamas vizuālās informācijas apstākļos.

Darba ietvaros tiek izskatīts sejas atpazīšanas uzdevums ierobežotās informācijas apstākļos – gadījumos, kad daļa no sejas ir noklāta ar masku vai galva ir pagriezta. Dziļais mākslīgais neironu tīkls, kurš bija apmācīts uz datu kopas ar redzamām sejām, tiks pārbaudīts uz datu kopas ar daļēji pieejamo vizuālo informāciju.

**Darba mērķis:** izpētīt neironu tīklu efektivitāti sejas atpazīšanai ierobežotās informācijas apstākļos.

### **Darba uzdevumi:**

1. Izpildīt literatūras analīzi par sejas atpazīšanas uzdevumu;
2. Izpildīt literatūras analīzi par mākslīgo neironu tīklu pielietošanu sejas atpazīšanai;
3. Izstrādāt eksperimentu plānu un sagatavot nepieciešamos datus;
4. Izpildīt eksperimentus, apkopot rezultātus un veikt secinājumus.

**Pētījuma jautājums:** cik efektīvs ir mākslīgais neironu tīkls sejas atpazīšanai ierobežotās informācijas apstākļos?

**Pētījuma metodes:** darbā tika pielietotas literatūras analīzes, salīdzinošās analīzes un eksperimentālās analīzes metodes.


# 1. TEORĒTISKĀ DAĻA

Teorētiskajā nodaļā tiek aprakstītas mākslīgu neironu tīklu funkcionēšanas pamati, izskatītas neironu tīklu bāzes elementi un to īpašības. Atsevišķi tiek izskatīta mākslīgo neironu tīklu pielietošanas sejas atpazīšanai tēma.

## 1.1. Mākslīgie neironu tīkli

Mākslīgos neironu tīklus vispiemērotāk var raksturot kā skaitļošanas modeļus tādām īpašībām, kā spēja pielāgoties vai iemācīties vispārināt vai grupēt vai organizēt datus, un kuras darbības pamatā ir paralēla datu apstrāde [2]. Mākslīgo neironu tīklu var definēt kā matemātisko modeli, kura pamatā ir bioloģisko neironu tīkls. Mākslīgais neironu tīkls ir savienoto neironu kopums, kur katras saites stiprumu (svarīgumu) nosaka svars. Tīklā apmācības laikā svāri tiek pielāgoti tā, lai minimizētu gala kļūdu [3]. Pastāv dažādas mākslīgo neironu tīklu struktūras, kuras izmanto uzraudzīto (*supervised*) un neuzraudzīto (*unsupervised*) apmācību. Sejas atpazīšanas uzdevums ir klasifikācijas uzdevums, kurš prasa apmācības datu kopu, kur jau ir noteiktas sejas robežas. Tāpēc tiek pielietoti mākslīgie neironu tīkli ar uzraudzīto apmācību.

Neironu tīkla fundamentālais elements ir neirons. Tā bāzē ir MakKalloka-Pitta mākslīgā neirona modelis (sk. 1.1. att.), kuru zinātnieki *Warren S. McCulloch* un *Walter Pitts* piedāvāja 1943. gadā [4]. Kopš tā laika piedāvātais modelis attīstījās, tomēr funkcionēšanas būtība palika. Neironam tiek sūtīts ieejas vektors  $X$  ar  $n$  vērtībām – ieejošais signāls. Katrai ieejošais vērtībai tiek piemērots svārs  $w_i$ , lai regulētu signāla svarīgumu un ietekmi uz gala rezultātu. Neirona kodolā svērtie signāli tiek summēti un tiek sūtīti uz aktivēšanas funkciju  $f(\cdot)$  un tiek aprēķināta neirona izeja –  $y$ .



1.1. att. MakKalloka-Pitta neirona modelis [5].


Klasiskajā MakKalloka-Pitta modelī tika lietota sliekšņa aktivēšanas funkcija (1) un pats modelis bija paredzēts lineāro uzdevumu risināšanai un nevarēja risināt nelineārus uzdevumus. Tāpēc, lai panākt nelineāro uzdevumu risināšanu, vairāki neironi tika apvienoti tīklā ar atsevišķiem neironu slāņiem, kur viena slāņa izeja tika sūtīta kā ieejas signāls nākamajam slānim līdz tika iegūts jau tīkla, nevis atsevišķa neiron izejas rezultāts. Šis modelis ir pazīstams kā daudzslāņu perceptrons (*Multilayer Perceptron*) (sk. 1.2. att.) [6] [7].

$$y = \begin{cases} 0, S < t \\ 1, S \geq t \end{cases} \quad (1)$$

kur

$y$  – neirona izeja;

$S$  – ieejas signālu svērtā summa;



**1.2. att. Daudzslāņu perceptrona modelis [8].**

Kā iepriekš bija minēts, apmācības rezultātā neironu tīklu svari tiek pielāgoti tā, lai minimizētu gala kļūdu. Vienkāršajā MakKalloka-Pitta modelī izeja ir tieši saistīta ar ieejas signālu un aprēķinot kļūdu, proporcionāli var pielāgot svarus. Tomēr daudzslāņu perceptronā, jeb daudzslāņu mākslīgajā neironu tīklā izeja nav tieši saistīta ar ieejas signālu, jo signāls aiziet caur vairākiem slēptiem slāņiem pirms tiks aprēķināta tīkla izeja. Šī īpašība radīja problēmas tīkla apmācībai līdz 1970. gadā Somijas magistratūras students *Seppo Linnainmaa* piedāvāja daudzslāņu mākslīgo neironu tīklu apmācības algoritmu, kurš tagad ir pazīstams kā kļūdas atgriezeniskās izplatīšanas algoritms – *Back-propagation algorithm* [9]. Algoritma pamatā ir gradienta samazināšanas metode. Vispirms tiek aprēķināts svaru izmaiņu gradients izejas slānim un tad tas tiek atgriezeniski izplatīts līdz ieejas slānim, rēķinot daļējos atvasinājumus. Kopējais gradients tīkla kļūdai  $E$  veidojas no vairākiem lokāliem gradientiem (2) [10].

$$\nabla E = \left( \frac{\partial E}{\partial w_1}, \frac{\partial E}{\partial w_2}, \dots, \frac{\partial E}{\partial w_l} \right), \quad (2)$$

kur

$$\frac{\partial E}{\partial w_i} - \text{lokālais gradients svaram } w_i.$$

Izmaiņas svaros tiek aprēķinātas, izmantojot attiecīga svara lokālo gradientu  $\frac{\partial E}{\partial w_i}$ , reizinātu ar apmācības koeficientu  $\gamma$  (3) [10].

$$\Delta w_i = \gamma \frac{\partial E}{\partial w_i}, \quad i = 1 \dots l \quad (3)$$


Kļūdas atgriezeniskās izplatīšanas algoritma īpašība, ka gradients tiek rēķināts kā daļējais atvasinājums no kļūdas pēc attiecīgā svara, pieprasa, lai neironos tiktu izmantotas differencējamās aktivēšanas funkcijas, citādi nebūs iespējams aprēķināt gradientu. Biežāk pielietotās aktivēšanas funkcijas ir loģistiskā funkcija (*sigmoid*) (4), hiperboliskais tangenss (5), ReLU (*Rectified Linear Unit*) (6) un *SoftPlus* (7) (sk. 1.3. att.), kā arī vienkārša lineārā funkcija. Minēto funkciju atvasinājumi ir ļoti zināmi un tas ir viens no iemesliem kāpēc tās ir bieži lietojamas.

$$f(S) = \frac{1}{1+e^{-S}} \quad (4)$$

$$f(S) = \tanh(S) = \frac{e^S - e^{-S}}{e^S + e^{-S}} \quad (5)$$

$$f(S) = \max(0, S) \quad (6)$$

$$f(S) = \frac{1}{k} \ln(1 + e^{kS}) \quad (7)$$



1.3. att. Apskatītās aktivēšanas funkcijas [11].

Kļūdas atgriezeniskās izplatīšanas algoritms ir vienkāršs un tāpēc tiek lietots praktiski visos mākslīgo neironu tīklos, kuri izmanto uzraudzītās apmācības pieeju, t.sk. konvolūciju neironu tīklos, kuri visbiežāk tiek pielietoti sejas atpazīšanas uzdevuma risināšanai.

## 1.2. Mākslīgie neironu tīkli sejas atpazīšanas uzdevumā


Sejas atpazīšana no reālajiem datiem, attēlu, sensoru attēlu un datu bāzes uzņemšana attēli ir izaicinoša problēma, jo sejas izskats ir ļoti atšķirīgs, pastāv apgaismojuma efekts un attēla fona sarežģītība arī ietekmē rezultātu. Sejas atpazīšanas procesā tiek analizētas personas sejas īpašības attēlā, izmantojot digitālo videokameru vai tiešsaistes sejas tveršanu. Vairāki pētnieki ir veica pētījumus par dažādiem sejas atpazīšanas pieejām, izmantojot mākslīgus neironu tīklus [12].

Biometrisko sistēmu pamatā ir četri bāzes soļi: sejas apgabala noteikšana, datu pirmapstrāde, īpašību izgūšana un sejas atpazīšana [12]. Sejas apgabala noteikšanas galvenā funkcija ir noteikt kur atrodas seja izvēlētajā attēlā. Šis sejas noteikšanas process faktiski pārbauda, vai attēlā ir personas seja, tad izgriež attēla apgabalu ar seju un nosuta to uz nākamo soli – datu pirmapstrāde. Priekšapstrādes posma tiek noņemts nevēlamais troksnis, izplūdums, ēnojums, koriģēts apgaismojums. Nākamajā solī notiek galveno īpašību izgūšana, tiek samazināts dimensiju skaits un filtrētas mazāk informatīvas īpašības. Rezultātā sejas attēls tiek transformēts vektorā ar noteikto garumu un tālāk tiek veikta sejas atpazīšana (klasificēšana) [12].

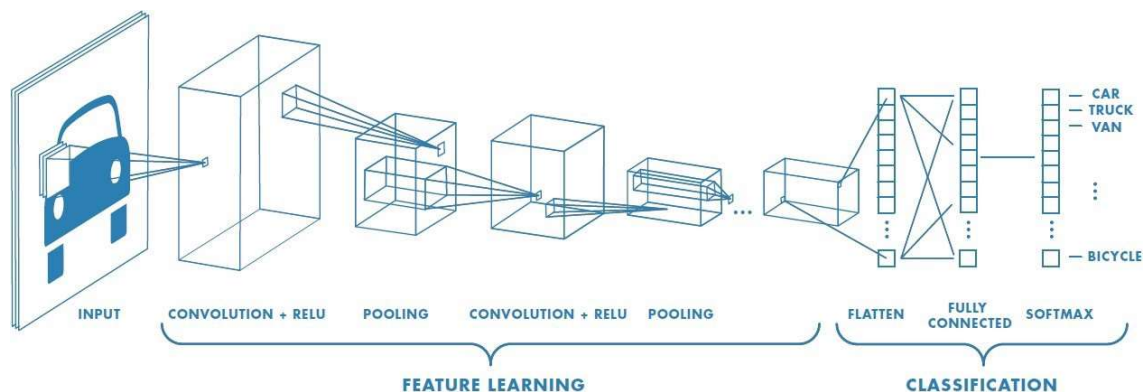
Viens no mākslīgo neironu tīklu veidiem, kurš biežāk tiek lietots vizuālo datu analīzei, ir konvolūciju neironu tīkli. Konvolūciju neironu tīklu pamatā ir konvolūcijas funkcija, kura atļauj samazināt dimensiju skaitu un nofiltrēt mazāk informatīvas īpašības – troksni [12]. Attēlā 1.4. ir parādīts konvolūcijas procedūras piemērs – no 4x4 matricas, izmantojot 3x3 filtru, tiek iegūta 2x2 matrica ar izgūtam īpašībām.

Konvolūciju neironu tīkla struktūra iekļauj vairākus konvolūciju slāņus, kuri secīgi filtrē datus un izgūst nozīmīgas īpašības (sk. 1.5. att.). Pēc tam dati tiek transformēti vektora formā un tad sūtīti neironu slāņiem, kuri faktiski ir daudzslāņu perceptrons, kurš apstrādā izgūtās svarīgās īpašības un veic datu klasifikāciju, kas darbā izskatītajā gadījumā ir sejas atpazīšana.

Atbilstoši darba mērķim, vairāk tiek pētīts tieši pirmais solis – sejas apgabala noteikšana. Pastāv dažādi rīki mākslīgo neironu tīklu veidošanai, tomēr darba ietvaros tika izskatīts gatavs risinājums – apmācīts neironu tīkls YOLOv3 [13] [14], kur jau ir realizēta sejas atpazīšanas funkcija.




1.4. att. Konvolūcijas procedūras piemērs [15].



1.5. att. Konvolūciju tīkla struktūras piemērs [16].

YOLO tīkls kā ieejas signālu saņem attēlu un tad veic to analīzi. Katram objektam, kurš tika atpazīts, tiek izvadīti 4 skaitļi:  $b_x$  un  $b_y$  – taisnstūra (apgabala) centrs;  $b_w$  – apgabala relatīvais platums (attiecībā pret attēla oriģinālo platumu);  $b_h$  – apgabala relatīvais augstums (attiecībā pret attēla oriģinālo augstumu) (sk. 1.6. att.). YOLOv3 tīkla struktūra ir parādīta un aprakstīta 1. pielikumā. Pamatojoties uz YOLOv3 tīkla autoru secinājumiem, YOLOv3 tīkls ir viens no ātrākiem konvolūciju neironu tīkliem, kurš var būt pielietots objektu atpazīšanai vizuālajos datos [13].



1.6. att. Izejas rezultāta interpretācija [13].



## 2. PRAKTISKĀ DAĻA

Praktiskās daļas ietvaros tiek plānots izmantot oriģinālo YOLOv3 tīklu un pārbaudīt tā efektivitāti sejas atpazīšanai pilnas pieejamas informācijas gadījumā – atklāto seju atpazīšana; un daļēji pieejamas informācijas gadījumā – daļēji nosegtu seju atpazīšana.

Oriģinālais, apmācītais YOLOv3 tīkls tika paņemts no to autoru avota [14], kur bija pieejams ne tikai tīkla struktūras apraksts, bet arī svari apmācītajam tīklam.

Atbilstoši darba uzdevumam tika sagatavotas divas datu kopas – ar atklātām sejām un ar daļēji nosegtām sejām. Abas datu kopas tika veidotas no attēliem, kuri tika ņemti no interneta no brīvi pieejamiem avotiem bez attēlu lietošanas ierobežojumiem. Kopumā tika izmantoti 78 attēli ar atklātām sejām un 56 attēli ar daļēji nosegtām sejām. Attēlā 2.1. ir parādīti izmantoto attēlu piemēri.




2.1. att. Izmantoto attēlu piemēri.

Veicot seju atpazīšanu izvēlētajos attēlos ar YOLOv3 tīklu, tika iegūti šādi rezultāti:

- Tīkls veiksmīgi noteica sejas apgabalu 68 no 78 attēliem ar atklātām sejām, kas sastāda 87.2%;
- Tīkls veiksmīgi noteica sejas apgabalu 18 no 56 attēliem ar daļēji nosegtām sejām, kas sastāda 32.1%.

Atpazīto un neatpazīto seju piemēri ir parādīti 2.2. attēlā. Apkopojot rezultātus var secināt, ka izmantotais mākslīgo neironu tīkls veiksmīgi noteica sejas uz attēliem, kur seja bija atklāta. Neatpazītās sejas, pārsvarā, bija attēlos, kur seja bija atklāta, bet vai nu pagriezta, vai daļēji nosegt ar matiem frizūras dēļ. Analizējot rezultātus ar datu kopu ar daļēji nosegtām sejām, var secināt, ka tīkls nevarēja atpazīt lielāko attēlu daļu. Tas ir saistīts galvenokārt ar to, ka izvēlētais mākslīgais neironu tīkls bija apmācīts uz datu kopas ar atklātām sejām un bija pielāgots to atpazīšanai. Kopumā visi ielānotie eksperimenti tika veiksmīgi izpildīti.



2.2. att. Atpazīto (zaļais taisnstūris) un neatpazīto seju piemēri.

## SECINĀJUMI

Darba izpildes rezultātā tika veikta mākslīgo neironu tīklu funkcionēšanas un pielietošanas analīze. Tika veikta analīze par mākslīgo neironu tīklu būtību un tika noteikts kā mākslīgo neironu tīklu fundamentāla ideja parādījās jau salīdzinoši sen – 1943. gadā tika piedāvāts mākslīga neirona modelis, kurš kļuva par pamatu daudzslāņu neironu tīkliem. Attīstoties datoru tehnoloģijām kļuva iespējams efektīvi realizēt pagājušā gadsimta vidū piedāvātās idejas un pielietot mākslīgus neironu tīklus dažādu nelineāro uzdevumu risināšanai. Darba ietvaros tika izpētīta vienkārša daudzslāņu neironu tīkla struktūra un kļūdas atgriezeniskās apmācības algoritms (sk. 1.1. apakšnodaļu).

Veicot literatūras un informāciju avotu analīzi par mākslīgo neironu tīklu pielietošanu vizuālo objektu, t.sk. sejas atpazīšanai, tika secināts, ka biežāk pielietotais mākslīgo neironu tīklu veids vizuālo datu analīzei ir konvolūciju neironu tīkli. Darba izpildes rezultātā tika noteikts, ka pastāv vairāki rīki mākslīgo neironu tīklu veidošanai, kā arī internetā ir pieejami jau apmācīti mākslīgie neironu tīkli specifisko uzdevumu risināšanai, t.sk. sejas atpazīšanai. Tāpēc praktisko eksperimentu veidošanai tika apgūts un izmantots konvolūciju neironu tīkls *YOLOv3* (sk. 1.2. apakšnodaļu).

Realizējot izstrādāto eksperimentu plānu, tika sagatavota datu kopa analīzei, kura saturēja 78 attēlus ar pilnīgi redzamu seju un 56 attēlus ar daļēji redzamu seju. Eksperimenta ietvaros sagatavotā datu kopa tika sūtīta uz *YOLOv3* neironu tīklu ar mērķi noteikt sejas apgabalu. Apkopojot iegūtus rezultātus tika secināts, ka tīkls, kurš tika apmācīts uz atklāto seju datu kopas, 87.2% gadījumos bija spējīgs atpazīt atklātu seju. Neatpazītās sejas pārsvarā bija vai nu pagrieztas vai daļēji noklātas ar matiem (frizūras dēļ). Savukārt veicot eksperimentu ar daļēji redzamām sejām, kuri pārsvarā bija noklāti ar sejas masku, kura noklāj muti un degumu, precizitāti bija tikai 32.1%.

No iegūtiem rezultātiem var secināt, ka tīkls, apmācītais atpazīt atklātu seju, nevar būt efektīvi pielietots daļēji noklātas sejas atpazīšanai. Šajā gadījumā, lai palielinātu tīkla efektivitāti, tas ir jāapmāca uz datu kopas, kura iekļauj ne tikai atklātas sejas, bet arī sejas maskā, grimā, pagrieztās sejas vai citādi noklātas.

Kopumā visi uzdevumi ir izpildīti un definētais mērķis ir sasniegts.

## LITERATŪRAS UN INFORMĀCIJU AVOTU SARAKSTS

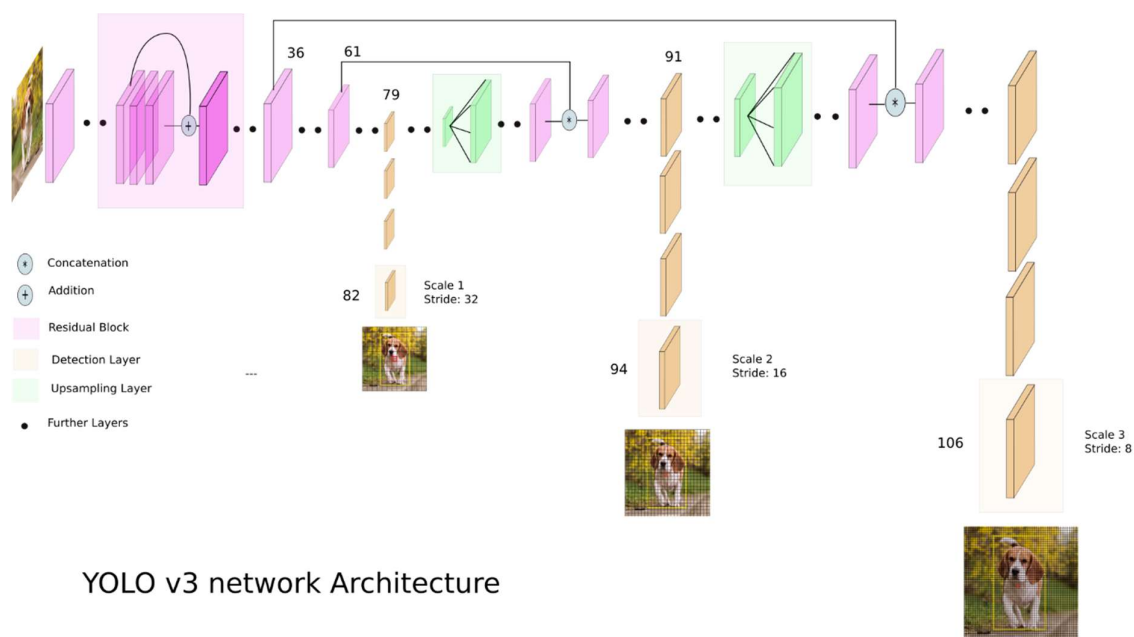
- [1] S. Anwarul and S. Dahiya. A Comprehensive Review on Face Recognition Methods and Factors Affecting Facial Recognition Accuracy, *Lecture Notes in Electrical Engineering*, 597, pp. 495-514, 2020.
- [2] B. Kröse and P. Van der Sma. An introduction to neural networks, The University of Amsterd, 1993.
- [3] S. Haykin. Neural Networks, 2nd Edition, Prentice Hall, 1998.
- [4] W. S. McCulloch and W. Pitts. A logical calculus of the ideas immanent in nervous activity, *Bulletin of Mathematical Biophysics*, vol. 5, no. 4, pp. 115-133, 1943.
- [5] S. Doherty. McCulloch-Pitts neuron [Online]. Available: [https://www.researchgate.net/figure/The-McCulloch-Pitts-Neuron\\_fig1\\_265486784](https://www.researchgate.net/figure/The-McCulloch-Pitts-Neuron_fig1_265486784). [Accessed 20.01.2021].
- [6] F. Rosenblatt. Principles of Neurodynamics: Perceptrons and the Theory of Brain Mechanisms, Washington DC: Spartan Books, 1961.
- [7] E. B. Baum. Capabilities of Multilayer Perceptrons, *Journal of Complexity*, vol. 4, pp. 193-215, 1988.
- [8] A. Hashemi, F. Madanifar and M. Abbasi. Implementation of multilayer perceptron (MLP) and radial basis function (RBF) neural networks to predict solution gas-oil ratio of crude oil systems, *Petroleum*, vol. 6, no. 1, pp. 80-91, 2020.
- [9] S. Linnainmaa. The representation of the cumulative rounding error of an algorithm as a Taylor expansion of the local rounding errors, Matrer's Thesis, University of Helsinki, 1970.
- [10] R. Rojas, Neural Networks - A Systematic Introduction, Springer, 1996.
- [11] Medium.com. Swish Activation Function [Online]. Available: <https://medium.com/@neuralnets/swish-activation-function-by-google-53e1ea86f820>. [Accessed 20.01.2021].
- [12] M. Kasar, D. Bhattacharyya and T. H. Kim. Face Recognition Using Neural Network: A Review, *International Journal of Security and its Applications*, vol. 10, no. 3, pp. 81-100, 2016.
- [13] J. Redmon and A. Farhadi. YOLOv3: An Incremental Improvement, *Journal arXiv*, 2018.
- [14] J. Redmon, YOLO: Real-Time Object Detection [Online]. Available: <https://pjreddie.com/darknet/yolo/>. [Accessed 20.01.2021].
- [15] L. Mosser, O. Dubrule and M. J. Blunt. Stochastic Reconstruction of an Oolitic Limestone by Generative Adversarial Networks, *Transport in Porous Media*, vol. 125, no. 2, pp. 81-103, 2018.
- [16] S. Saha. A Comprehensive Guide to Convolutional Neural Networks — the ELI5 way, [Online]. Available: <https://towardsdatascience.com/a-comprehensive-guide-to-convolutional-neural-networks-the-eli5-way-3bd2b1164a53>. [Accessed 20.01.2021].
- [17] A. Kathuria. What's new in YOLO v3?, [Online]. Available: <https://towardsdatascience.com/yolo-v3-object-detection-53fb7d3bfe6b>. [Accessed 20.01.2021].

# PIELIKUMI

## 1. pielikums

YOLOv3 tīkla struktūra [13] [17]

	Type	Filters	Size	Output
	Convolutional	32	$3 \times 3$	$256 \times 256$
	Convolutional	64	$3 \times 3 / 2$	$128 \times 128$
1x	Convolutional	32	$1 \times 1$	
	Convolutional	64	$3 \times 3$	
	Residual			$128 \times 128$
	Convolutional	128	$3 \times 3 / 2$	$64 \times 64$
2x	Convolutional	64	$1 \times 1$	
	Convolutional	128	$3 \times 3$	
	Residual			$64 \times 64$
	Convolutional	256	$3 \times 3 / 2$	$32 \times 32$
8x	Convolutional	128	$1 \times 1$	
	Convolutional	256	$3 \times 3$	
	Residual			$32 \times 32$
	Convolutional	512	$3 \times 3 / 2$	$16 \times 16$
8x	Convolutional	256	$1 \times 1$	
	Convolutional	512	$3 \times 3$	
	Residual			$16 \times 16$
	Convolutional	1024	$3 \times 3 / 2$	$8 \times 8$
4x	Convolutional	512	$1 \times 1$	
	Convolutional	1024	$3 \times 3$	
	Residual			$8 \times 8$
	Avgpool		Global	
	Connected		1000	
	Softmax			



YOLO v3 network Architecture